

# Aprendizaje automático

Clase 2

Iris Sattolo, Maximiliano Beckel



# Medidas de Performance

Existe una gran cantidad de Medidas de Performance.

¿Cuál es la mejor? Va a depender de los datos y del modelo que elijamos.

Veamos una de esas medidas:

**Accuracy**: proporción de aciertos.

$$\text{Accuracy} = \frac{\text{Predicciones correctas}}{\text{Predicciones totales}}$$

**Ej:** con mi modelo para clasificar manzanas y frutillas quiero clasificar 20 frutas desconocidas. De las 20 mi modelo clasifica 15 correctamente y 5 de forma equivocada. ¿Cuál es el accuracy?  $15/20 = 0.75$

**Problema:** ¿Qué pasaría si yo quiero hacer un modelo que prediga si hoy va a caer un meteorito gigante o no?



**¡Datos desbalanceados!**



# ¿Qué otras alternativas tenemos?

## Diferentes métricas/términos

| Inglés           | Español              |
|------------------|----------------------|
| Precision        | Precisión            |
| Recall           | Exhaustividad        |
| F1-score         | Valor-F              |
| Accuracy         | Exactitud            |
| Confusion Matrix | Matriz de Confusión  |
| True Positive    | Positivos Verdaderos |
| True Negative    | Negativos Verdaderos |
| False Positive   | Positivos Falsos     |
| False Negative   | Negativos Falsos     |

Vamos con un ejemplo...

Trabajamos para un banco (sin alma pero con lindo sueldo). El banco quiere lanzar una nueva tarjeta de crédito para sus clientes por lo que está organizando una campaña de marketing. Para que sus clientes se sientan importantes piensa mandarles una carta personalizada a su domicilio contando las bondades y beneficios de la nueva tarjeta de crédito. El problema es que eso cuesta dinero, por lo que no le puede enviar cartitas a todos los clientes.

Ahí entramos nosotros...

Desafío: Realizar un modelo de machine learning que intente predecir cuáles son los clientes que tienen más chances de aceptar la nueva tarjeta si les dirijo la campaña de marketing a ellos.



Supongamos que hacemos el modelo... **Dado un cliente, ¿qué puede llegar a ocurrir?**

**Opción 1:** Mi modelo predijo que va a querer la tarjeta, le envié la carta y LA ACEPTÓ! **TRUE POSITIVE (TP)**

**Opción 2:** Mi modelo predijo que no va a querer la tarjeta pero la HUBIERA ACEPTADO si se la enviaba **FALSE NEGATIVE (FN)**

**Opción 3:** Mi modelo predijo que va a querer la tarjeta, le envié la carta y NO LA ACEPTÓ! **FALSE POSITIVE (FP)**

**Opción 4:** Mi modelo predijo que no va a querer la tarjeta y efectivamente NO LA HUBIERA ACEPTADO! **TRUE NEGATIVE (TN)**

Para evaluar el modelo, se eligieron al azar un total 100 clientes, se hicieron las predicciones correspondientes PERO se enviaron las cartas a TODOS los clientes. ¿Por qué? Porque lo que quiero hacer es evaluar si el modelo hace buenas predicciones o no.

Del total de clientes seleccionados, **80** de ellos RECHAZAN la tarjeta y **20** la ACEPTAN.

Ahora podemos comparar la predicción de mi modelo con la realidad utilizando una MATRIZ DE CONFUSIÓN:

|          |   | predicción |    |
|----------|---|------------|----|
|          |   | 0          | 1  |
| realidad | 0 | 70         | 10 |
|          | 1 | 15         | 5  |

|          |   | predicción |    |
|----------|---|------------|----|
|          |   | 0          | 1  |
| realidad | 0 | TN         | FP |
|          | 1 | FN         | TP |



Supongamos que hacemos el modelo... **Dado un cliente, ¿qué puede llegar a ocurrir?**

**Opción 1:** Mi modelo predijo que va a querer la tarjeta, le envié la carta y LA ACEPTÓ! **TRUE POSITIVE (TP)**

**Opción 2:** Mi modelo predijo que no va a querer la tarjeta pero la HUBIERA ACEPTADO si se la enviaba **FALSE NEGATIVE (FN)**

**Opción 3:** Mi modelo predijo que va a querer la tarjeta, le envié la carta y NO LA ACEPTÓ! **FALSE POSITIVE (FP)**

**Opción 4:** Mi modelo predijo que no va a querer la tarjeta y efectivamente NO LA HUBIERA ACEPTADO! **TRUE NEGATIVE (TN)**

Para evaluar el modelo, se eligieron al azar un total 100 clientes, se hicieron las predicciones correspondientes PERO se enviaron las cartas a TODOS los clientes. ¿Por qué? Porque lo que quiero hacer es evaluar si el modelo hace buenas predicciones o no.

Del total de clientes seleccionados, **80** de ellos RECHAZAN la tarjeta y **20** la ACEPTAN.

Ahora podemos comparar la predicción de mi modelo con la realidad utilizando una MATRIZ DE CONFUSIÓN:

|          |   | predicción |    |
|----------|---|------------|----|
|          |   | 0          | 1  |
| realidad | 0 | 70         | 10 |
|          | 1 | 15         | 5  |

|          |   | predicción |    |
|----------|---|------------|----|
|          |   | 0          | 1  |
| realidad | 0 | TN         | FP |
|          | 1 | FN         | TP |





Supongamos que hacemos el modelo... **Dado un cliente, ¿qué puede llegar a ocurrir?**

**Opción 1:** Mi modelo predijo que va a querer la tarjeta, le envié la carta y LA ACEPTÓ! **TRUE POSITIVE (TP)**

**Opción 2:** Mi modelo predijo que no va a querer la tarjeta pero la HUBIERA ACEPTADO si se la enviaba **FALSE NEGATIVE (FN)**

**Opción 3:** Mi modelo predijo que va a querer la tarjeta, le envié la carta y NO LA ACEPTÓ! **FALSE POSITIVE (FP)**

**Opción 4:** Mi modelo predijo que no va a querer la tarjeta y efectivamente NO LA HUBIERA ACEPTADO! **TRUE NEGATIVE (TN)**

Para evaluar el modelo, se eligieron al azar un total 100 clientes, se hicieron las predicciones correspondientes PERO se enviaron las cartas a TODOS los clientes. ¿Por qué? Porque lo que quiero hacer es evaluar si el modelo hace buenas predicciones o no.

Del total de clientes seleccionados, **80** de ellos RECHAZAN la tarjeta y **20** la ACEPTAN.

Ahora podemos comparar la predicción de mi modelo con la realidad utilizando una MATRIZ DE CONFUSIÓN:

|          |   | predicción |    |
|----------|---|------------|----|
|          |   | 0          | 1  |
| realidad | 0 | 70         | 10 |
|          | 1 | 15         | 5  |

|          |   | predicción |    |
|----------|---|------------|----|
|          |   | 0          | 1  |
| realidad | 0 | TN         | FP |
|          | 1 | FN         | TP |



¿Qué proporción de todos los envíos que hubiera hecho con mi modelo serían correctos?



## Precision (Precisión)

Para calcular la precisión usaremos la siguiente fórmula:

$$precision = \frac{TP}{TP + FP}$$

|          |   | predicción |    |
|----------|---|------------|----|
|          |   | 0          | 1  |
| realidad | 0 | TN         | FP |
|          | 1 | FN         | TP |

Precisión (precision)

En el ejemplo de marketing, siguiendo los datos de la matriz de confusión, tenemos que:

$$precision = \frac{TP}{TP + FP} = \frac{5}{5 + 10} = 0.33$$

¿Qué proporción de todos los clientes que podrían aceptar la tarjeta logro recuperar con mi modelo?



## Recall (Exhaustividad)

Para calcular la exhaustividad (recall) usaremos la siguiente fórmula:

$$recall = \frac{TP}{TP + FN}$$

|          |   | predicción |    |
|----------|---|------------|----|
|          |   | 0          | 1  |
| realidad | 0 | TN         | FP |
|          | 1 | FN         | TP |

Exhaustividad (recall)

En el ejemplo de marketing, siguiendo los datos de la matriz de confusión, tenemos que:

$$recall = \frac{TP}{TP + FN} = \frac{5}{5 + 15} = 0.25$$

# F1

¿Qué elijo, precision o recall? ¡Por qué elegir! F1 es una métrica que combina precision y recall en una única escala numérica.

F1 se calcula haciendo la media armónica entre la precisión y la exhaustividad:

$$F1 = 2 \cdot \frac{precision \cdot recall}{precision + recall}$$

En el ejemplo de marketing, combinando precision y recall en F1 nos quedaría:

$$F1 = 2 \cdot \frac{precision \cdot recall}{precision + recall} = 2 \cdot \frac{0.33 \cdot 0.25}{0.33 + 0.25} = 0.28$$

En la métrica F1 se le da la misma importancia a la precision y a recall, pero esto puede no ser la mejor opción en todas las situaciones (¿Se acuerdan del problema del meteorito?). En aquellos casos en los que queremos que una métrica tenga más importancia que la otra se puede utilizar la fórmula general en la que Beta puede ser distinto a 1.

En este caso podemos usar F2, que es la fórmula genérica del valor F para beta = 2. La fórmula genérica de F es la siguiente:

$$F_{\beta} = (1 + \beta^2) \cdot \frac{precision \cdot recall}{(\beta^2 \cdot precision) + recall}$$

Entonces... ¿Mi modelo es bueno o malo?

Si en este ejemplo calculamos el accuracy obtenemos un valor de 0.75 (75/100). Ese resultado nos puede hacer pensar que nuestro modelo no está tan mal (el máximo accuracy posible es 1).

Sin embargo, cuando calculamos el resto de las métricas vemos que a nuestro modelo le va bastante mal:

- Precision: 0.33
- Recall: 0.25
- F1: 0.28


Por lo que nuestro modelo no es tan bueno como pensábamos...

Todas estas métricas (y más) pueden calcularse fácilmente con scikit-learn:

- [`sklearn.metrics.confusion\_matrix`](#)
- [`sklearn.metrics.precision\_score`](#)
- [`sklearn.metrics.recall\_score`](#)
- [`sklearn.metrics.f1\_score`](#)
- [`sklearn.metrics.accuracy\_score`](#)



# AUC: Área bajo la curva ROC... ¿Y qué es una curva ROC?




La curva ROC representa la relación que hay entre el TRUE POSITIVE RATE (también conocido como sensibilidad) y el FALSE POSITIVE RATE (también conocido como 1 - especificidad).


La curva se construye variando el criterio elegido para considerar un caso como positivo. En nuestro ejemplo, podría ser la probabilidad a partir de la cual vamos a considerar que un cliente va a aceptar la nueva tarjeta de crédito.

Cuanto más cerca de esté la curva de la esquina superior izquierda del gráfico mejor será nuestro modelo (¿Por qué?). Por lo que se suele tomar como medida de performance de un modelo el área que queda por debajo de esta curva (AUC).

Ver: [Aqui](#)



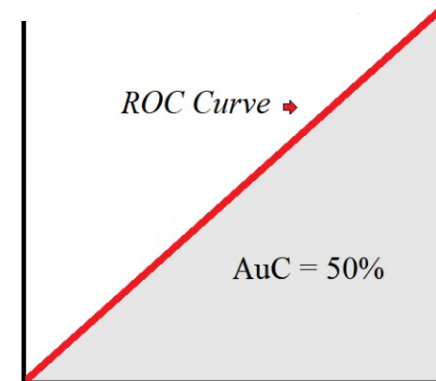
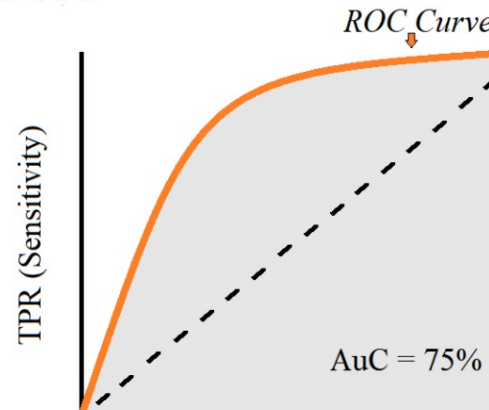

# AUC: Área bajo la curva ROC... ¿Y qué es una curva ROC?



La curva ROC representa la relación que hay entre el TRUE POSITIVE RATE (también conocido como sensibilidad) y el FALSE POSITIVE RATE (también conocido como 1 - especificidad).

La curva se construye variando el criterio elegido para considerar un caso como positivo. En nuestro ejemplo, podría ser la probabilidad a partir de la cual vamos a considerar que un cliente va a aceptar la nueva tarjeta de crédito.

Cuanto más cerca de esté la curva de la esquina superior izquierda del gráfico mejor será nuestro modelo (¿Por qué?). Por lo que se suele tomar como medida de performance de un modelo el área que queda por debajo de esta curva (AUC).



¿Este caso es posible?

